

Đề xuất triển khai AI nội bộ

1. Mục đích và yêu cầu

Tài liệu trả lời các câu hỏi:

- (1) Phương án chạy AI server local với model mã nguồn mở, truy cập qua VPN, kèm cấu hình phần cứng;
- (2) Nếu dùng dịch vụ trả phí thì có những lựa chọn nào và việc dùng chung tài khoản trong team thực tế ra sao;
- (3) Phương án khác;
- (4) Kế hoạch triển khai và đào tạo.


Các nhu cầu sử dụng AI đã xác định:

- Testing, validation và tóm tắt trạng thái (status summary) tự động.
- Phân tích vấn đề kỹ thuật (analyze).
- Review code, chuẩn hoá coding style, bổ sung comment.
- Hỗ trợ khách hàng (customer support).
- Thu thập thông tin thị trường định kỳ: UWB, RTLS, xu hướng và nhu cầu theo lĩnh vực.

2. Option 1 - AI server local với model mã nguồn mở

Phương án bảo mật nhất: toàn bộ dữ liệu (mã nguồn, tài liệu khách hàng) không rời khỏi hạ tầng của công ty. Nhân viên truy cập qua VPN từ văn phòng hoặc từ xa.

2.1. Kiến trúc



Hình 1: Kiến trúc truy cập AI server local qua VPN.

- **Hệ điều hành:** Ubuntu Server 24.04 LTS + Docker.
- **Inference engine:** vLLM cho môi trường nhiều người dùng đồng thời (PagedAttention, throughput cao); Ollama chỉ phù hợp thử nghiệm cá nhân.
- **Giao diện:** Open WebUI - mã nguồn mở, nhiều người dùng, phân quyền admin/user, tách riêng hội thoại từng người, RAG tích hợp (hỏi đáp trên tài liệu nội bộ), hỗ trợ SSO/LDAP.
- **API gateway (tuỳ chọn):** LiteLLM proxy - cấp key ảo cho từng người, đặt hạn mức, gom model local và cloud về một endpoint.
- **VPN:** Tailscale (gần như không cần cấu hình, miễn phí tới 3 user/100 thiết bị) hoặc WireGuard tự dựng (miễn phí hoàn toàn).

Nguồn / tài liệu hướng dẫn:

- <https://docs.openwebui.com/>
- <https://docs.vllm.ai/en/latest/deployment/frameworks/open-webui/>
- <https://docs.litellm.ai/>
- <https://tailscale.com/pricing>
- <https://www.wireguard.com/>

2.2. Model mã nguồn mở tiêu biểu

Bảng xếp hạng các model mã nguồn mở hàng đầu theo benchmark tổng hợp (Top open source LLMs ranked by benchmarks, benchlm.ai, 06/2026):

Hạng	Model	Nhà phát triển	Điểm tổng (Overall)	Context
1	DeepSeek V4 Pro (Max)	DeepSeek	87	1M
2	Kimi K2.6	Moonshot AI	84	256K
3	GLM-5 (Reasoning)	Zhipu AI	81	200K
4	GLM-5.1	Zhipu AI	83	203K
5	DeepSeek V4 Pro (High)	DeepSeek	83	1M
6	Qwen3.5 397B (Reasoning)	Alibaba	77	128K
7	DeepSeek V4 Flash (Max)	DeepSeek	77	1M
8	Qwen3.6-27B	Alibaba	75	262K

Các model top đầu có quy mô hàng trăm tỷ tham số nên cần hạ tầng GPU lớn; với cấu hình server ở mục 2.3, phù hợp là các bản nhỏ (ví dụ Qwen3.6-27B) hoặc bản distill/quantized của các model trên.

So sánh nhanh khả năng coding của các model mở (điểm càng cao càng tốt, nguồn: benchlm.ai):

Model	Điểm coding tổng hợp	LiveCodeBench	SWE-bench Verified
DeepSeek V4 Pro (Max)	89.8	93.5	-
Kimi K2.6	88.7	89.6	-
DeepSeek V4 Pro (High)	88.7	-	-
Qwen3.5 397B (Reasoning)	86.7	-	-
GLM-5.1	84.1	-	77.8
GLM-5 (Reasoning)	-	-	77.8
DeepSeek V4 Flash (Max)	-	91.6	-

Tham khảo từ:
- <https://benchlm.ai/blog/posts/best-open-source-llm>
- <https://huggingface.co/blog/daya-shankar/open-source-llms>

Dẫn chứng so sánh khả năng coding giữa các model (leaderboard cập nhật liên tục, gồm cả model mở và model thương mại):
- <https://www.swebench.com/>
- <https://aider.chat/docs/leaderboards/>
- <https://livecodebench.github.io/leaderboard.html>
- <https://evalplus.github.io/leaderboard.html>

2.3. Cấu hình phần cứng tham khảo

Hạng mục	Tier A - Khởi điểm	Tier B - Tầm trung	Tier C - Phương án Mac
GPU	1× NVIDIA RTX 5090 32 GB GDDR7	2× RTX 5090 (64 GB tổng) hoặc 1× RTX PRO 6000 Blackwell 96 GB	Apple M3 Ultra, GPU 80 nhân, unified memory
CPU	Ryzen 9 7950X / Core i9 (8+ nhân)	Threadripper / Xeon W (đủ lane PCIe cho 2 GPU)	-
RAM	64 GB DDR5	128-256 GB DDR5 ECC	256-512 GB unified memory
Lưu trữ	NVMe 2 TB	NVMe 4 TB (model + dữ liệu RAG)	2-4 TB SSD
Nguồn / khác	PSU 1000 W	PSU 1600 W, vỏ máy thoáng khí, UPS	Tiêu thụ điện rất thấp
Model chạy được	≤ 32B Q4 (Qwen3 32B, Gemma 3 27B, gpt-oss-20b)	70B Q4, gpt-oss-120b, Qwen3 235B-A22B (bản quantized)	Model rất lớn (DeepSeek R1 671B ~17-18 token/giây)

Hạng mục	Tier A - Khởi điểm	Tier B - Tầm trung	Tier C - Phương án Mac
Người dùng đồng thời	~3-5	~10-20 với vLLM	1-3 (yếu khi nhiều người dùng đồng thời)
Dẫn chứng phần cứng phù hợp model	RTX 5090 32 GB đủ chạy các model quantized cỡ ~30B: runpod.io (RTX 5090 LLM guide)	70B Q4 cần ~40 GB VRAM, 2x RTX 5090 hoặc card 96 GB đáp ứng: runpod.io (RTX 5090 LLM guide) , bizon-tech.com (best GPU for LLM)	M3 Ultra 512 GB chạy DeepSeek R1 671B ~17-18 token/giây: medium.com (M3 Ultra LLM inference) , apple.com/mac-studio/specs
Chi phí ước tính	≈ 2.500-3.500 USD	≈ 7.000-12.000 USD	≈ 5.600 USD (256 GB) - 9.500 USD (512 GB)

Cơ sở tính toán: model 70B ở FP16 cần ~140 GB VRAM, quantize 4-bit (Q4_K_M) còn ~40 GB - vượt 32 GB của một card RTX 5090 nên cần 2 GPU hoặc card 96 GB. Mac Studio chạy được model rất lớn nhờ unified memory nhưng tốc độ xử lý prompt dài (prefill) và khả năng phục vụ đồng thời kém hơn GPU NVIDIA.

- Tham khảo từ:
- <https://www.nvidia.com/en-us/geforce/graphics-cards/50-series/rtx-5090/>
 - <https://www.nvidia.com/en-us/products/workstations/professional-desktop-gpus/rtx-pro-6000/>
 - <https://www.runpod.io/articles/guides/nvidia-rtx-5090>
 - <https://bizon-tech.com/blog/best-gpu-llm-training-inference>
 - <https://www.apple.com/mac-studio/specs/>
 - <https://medium.com/@billynewport/apples-m3-ultra-mac-studio-misses-the-mark-for-llm-inference-f57f1f10a56f>

2.4. Đánh giá

Ưu điểm	Hạn chế
Dữ liệu 100% trong nội bộ; không phí thuê bao theo người dùng; không giới hạn số lượt dùng; chủ động tùy biến (RAG tài liệu nội bộ, fine-tune).	Chất lượng model mở 32B-120B vẫn thấp hơn model thương mại hàng đầu ở tác vụ khó; cần người vận hành (cập nhật model, backup, giám sát); không tự tìm kiếm web nếu không tích hợp thêm; chi phí đầu tư ban đầu.

3. Option 2 - Dịch vụ AI trả phí (theo tháng / theo năm)

3.1. Các lựa chọn

Dịch vụ	Giá/người/tháng	Ghi chú
ChatGPT Business (OpenAI) openai.com/chatgpt-pricing	25 USD (theo tháng) / 20 USD (theo năm)	Tối thiểu 2 chỗ; workspace riêng; dữ liệu không bị dùng để huấn luyện
Claude Team Standard (Anthropic) claude.com/pricing	25 USD (theo tháng) / 20 USD (theo năm)	Tối thiểu 5 chỗ; SSO, quản trị tập trung; không huấn luyện trên dữ liệu team
Claude Team Premium claude.com/pricing	125 USD (theo tháng) / 100 USD (theo năm)	Như Standard + Claude Code (agent lập trình trong terminal/IDE)
Cursor Pro / Teams cursor.com/pricing	20 USD (Pro) / 40 USD (Teams)	IDE lập trình có AI; mỗi tháng kèm hạn mức sử dụng model tương ứng giá gói
GitHub Copilot Business github.com/copilot/plans	19 USD	Gợi ý code trong IDE; hỗ trợ chứ không thay thế chat AI



Hình 2: Khả năng coding của model đứng sau từng dịch vụ - điểm SWE-bench Verified (% issue GitHub thật được giải đúng), 06/2026. Cursor và Copilot chạy chính các model trên nên khả năng coding phụ thuộc model được chọn.

Dẫn chứng so sánh khả năng coding của các model thương mại (Claude, GPT, Gemini...) trên leaderboard độc lập:

- <https://benchlm.ai/benchmarks/sweVerified>
- <https://www.swebench.com/>
- <https://aider.chat/docs/leaderboards/>
- <https://lmarena.ai/leaderboard>
- <https://livecodebench.github.io/leaderboard.html>

3.2. Dùng chung tài khoản trong team - được, nhưng chạm giới hạn rất nhanh

Về kỹ thuật, nhiều người có thể đăng nhập chung một tài khoản, nhưng **giới hạn sử dụng tính trên tài khoản** nên sẽ cạn rất nhanh khi dùng chung:

- **Claude (Pro/Max):** giới hạn theo **phiên 5 giờ** (tính từ prompt đầu tiên) cộng thêm **giới hạn theo tuần**; mọi kênh (web, IDE, Claude Code) trừ chung một quota. Gói Pro chỉ khoảng 10-45 prompt mỗi phiên 5 giờ tùy độ dài. Nguồn: support.claude.com - [How do usage and length limits work](#).
- **ChatGPT Plus:** khoảng **160 tin nhắn GPT-5.5 mỗi 3 giờ**; vượt giới hạn thì tự rơi xuống bản mini. Nguồn: help.openai.com - [GPT-5.5 in ChatGPT](#). Gói Business: gần như không giới hạn với model cơ bản, nhưng tính theo seat từng người. Nguồn: help.openai.com - [ChatGPT Business Models & Limits](#).
- **Cursor:** giới hạn theo **tháng** - gói Pro 20 USD kèm ~20 USD chi phí model mỗi tháng, dùng hết thì dừng (hoặc trả thêm theo nhu cầu nếu bật spend limit). Nguồn: cursor.com/pricing, cursor.com/blog/june-2025-pricing.
- **Giới hạn phụ thuộc context/token, không phải số câu hỏi:** các nhà cung cấp đo quota theo lượng token xử lý. Hội thoại dài, đính kèm file lớn, đưa nhiều code vào context sẽ tiêu tốn quota nhanh gấp nhiều lần - nên càng nhiều người dùng chung một tài khoản thì càng chạm trần sớm.
- Ngoài ra, chia sẻ tài khoản cá nhân nằm ngoài phạm vi điều khoản sử dụng của các dịch vụ; hình thức chính thức cho team là gói Business/Team theo seat.

4. Phương án khác

4.1. Thuê GPU cloud

Thuê GPU theo giờ để chạy chính các model mã nguồn mở ở mục 2. Ưu điểm:

- Không cần vốn đầu tư ban đầu - trả theo giờ sử dụng thực tế.
- Thử được nhiều cấu hình GPU khác nhau trước khi quyết định mua phần cứng.
- Nâng/hạ cấu hình linh hoạt theo nhu cầu; có việc nặng thì thuê máy mạnh hơn vài giờ.
- Dùng được ngay trong lúc chờ mua máy, không gián đoạn kế hoạch.

4.2. Bảng so sánh các phương án

Tiêu chí	Option 1 - Server local	Option 2 - Dịch vụ trả phí	Thuê GPU cloud
Bảo mật dữ liệu	Cao nhất - dữ liệu không rời công ty	Phụ thuộc nhà cung cấp (có cam kết không train)	Dữ liệu đi qua hạ tầng bên thuê
Chất lượng AI	Khá (model mở 32B-120B)	Cao nhất (model thương mại mới nhất)	Như Option 1 (cùng model mở)
Chi phí ban đầu	2.500-12.000 USD tùy tier	0	0
Chi phí hằng tháng	Điện + bảo trì	20-125 USD/người tùy gói	Theo giờ sử dụng
Giới hạn sử dụng	Không	Theo phiên/tuần/tháng tùy dịch vụ (mục 3.2)	Không (trong giờ đã thuê)

Tiêu chí	Option 1 - Server local	Option 2 - Dịch vụ trả phí	Thuê GPU cloud
Tìm kiếm web	Phải tích hợp thêm	Có sẵn	Phải tích hợp thêm
Công sức vận hành	Cần người phụ trách	Không đáng kể	Trung bình

5. Kế hoạch triển khai

Thời gian	Công việc chính	Kết quả
Tuần 1, ngày 1-2	Chốt phương án và ngân sách; quy định dữ liệu nào được/không được đưa lên cloud; tạo tài khoản; dựng Open WebUI (+ LiteLLM nếu dùng API) trên máy tạm; cấu hình VPN Tailscale/WireGuard	Cả nhóm bắt đầu dùng được AI qua web nội bộ
Tuần 1, ngày 3-5	Dựng server model mở: cài Ubuntu + Docker + vLLM, tải model (Qwen3 32B, Qwen2.5-Coder); nếu chưa có phần cứng thì thuê GPU cloud chạy tạm	Model mã nguồn mở hoạt động, truy cập qua VPN
Tuần 2	Tích hợp use case: AI review code trên Git, RAG tài liệu nội bộ, script tóm tắt kết quả test, agent tổng hợp tin thị trường UWB/RTLS; quay video demo hướng dẫn (mục 6); ban hành quy định sử dụng AI	AI gắn vào quy trình hằng ngày, có tài liệu hướng dẫn

Nếu phải đặt mua phần cứng, thời gian chờ hàng nằm ngoài 2 tuần này - trong lúc chờ dùng GPU thuê.

6. Đào tạo cho nhóm

- **Quay video demo cách setup** (5-10 phút/video, quay màn hình): cài và kết nối VPN, đăng nhập Open WebUI, kết nối agent trong IDE/terminal, cấu hình API key nội bộ - lưu vào drive nội bộ để nhân viên mới tự setup được bất cứ lúc nào.
- **Tổng hợp link tài liệu viết prompt** gửi cả nhóm:
Tài liệu hướng dẫn viết prompt:
- <https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview>
- <https://platform.openai.com/docs/guides/prompt-engineering>
- <https://www.promptingguide.ai/>
- Cheat sheet 1 trang: các mẫu prompt dùng ngay cho công việc của công ty.

7. Ánh xạ nhu cầu sử dụng → giải pháp

Nhu cầu	Giải pháp	Model/Công cụ
Testing, validation, tóm tắt trạng thái	Script gọi model qua API nội bộ: đọc log test/CI, sinh báo cáo tóm tắt hằng ngày gửi vào kênh chat	Qwen3 32B (local) - dữ liệu nội bộ
Phân tích vấn đề	Chat trực tiếp; vấn đề khó dùng model mạnh hơn	Claude/GPT (cloud) hoặc DeepSeek-R1-Distill (local)
Review code, coding style, comment	Tích hợp vào Git: AI review tự động từng merge request; kỹ sư dùng agent trong terminal/IDE	Qwen2.5-Coder (local), Claude Code / Cursor (cloud)
Hỗ trợ khách hàng	Chatbot hỏi đáp trên tài liệu docs.leapslabs.com theo mô hình RAG (chi tiết mục 9)	Open WebUI Knowledge (local)
Theo dõi thị trường UWB/RTLS	Script crawl tin từ danh sách nguồn cố định; AI chỉ tóm tắt và phân loại; gửi notification (chi tiết mục 8)	Script crawl + model local hoặc API
Phát triển ứng dụng mới	Làm thử 1 ứng dụng nhỏ trong 2 tuần bằng AI pair-programming để đánh giá tốc độ thực tế - bản riêng để chọn ứng dụng thí điểm	Claude Code / Cursor + khung dự án chuẩn

8. Theo dõi thông tin thị trường UWB/RTLS

Chúng ta xây script crawl tin từ danh sách website cố định; AI đảm nhận phần **tóm tắt và phân loại**; cuối cùng hệ thống gửi thông báo. Quy trình 4 bước:

- **Bước 1 - Chốt danh sách nguồn:** các website/RSS ở bảng dưới, có thể thêm bớt theo thời gian.
- **Bước 2 - Script crawl tin:** Python ([feedparser](#) đọc RSS; requests + [BeautifulSoup](#) cho trang không có RSS), chạy cron mỗi ngày, lưu bài mới vào database và loại bài trùng. Ai không muốn code có thể dùng [n8n](#) (no-code, self-host được).
- **Bước 3 - AI tóm tắt và phân loại:** với mỗi bài mới, model tóm tắt 3-5 câu tiếng Việt và gán nhãn (UWB / RTLS / chip và phần cứng / đối thủ / báo cáo thị trường / ứng dụng ngành: ô tô, y tế, logistics...), chấm điểm mức liên quan 1-5 và bỏ qua bài dưới ngưỡng. Tin tức là dữ liệu công khai nên dùng model local (Qwen3 32B) hay API đều được.
- **Bước 4 - Notification:** bản tin tổng hợp hằng tuần gửi qua email/Slack/Teams; bài điểm liên quan cao gửi ngay trong ngày.

Danh sách website nguồn đề xuất:

Nguồn	Nội dung chính
FiRa Consortium firaconsortium.org	Tổ chức chuẩn hoá UWB: tin chứng nhận, thành viên mới, use case chuẩn
UWB Alliance uwballiance.org	Hệ sinh thái UWB, vận động chính sách tần số
omlox omlox.com	Chuẩn định vị mở cho công nghiệp (UWB là công nghệ lõi)
RFID Journal rfidjournal.com	Tin RTLS, định vị tài sản, case study triển khai thực tế trong kho vận, y tế, sản xuất
everything RF everythingrf.com/news	Tin chip/module RF và UWB mới ra mắt
NXP Newsroom nxp.com (newsroom)	Chip UWB Trimension, hợp tác với ngành ô tô và điện thoại
Qorvo Newsroom qorvo.com/newsroom	Dòng chip UWB DW3000 (gốc Decawave) và tin ngành
Sewio Blog sewio.net/blog	RTLS UWB trong nhà máy; bài so sánh công nghệ định vị (theo dõi đối thủ)
MarketsandMarkets / Grand View Research marketsandmarkets.com (UWB report) , grandviewresearch.com (UWB report)	Báo cáo quy mô và dự báo thị trường UWB cập nhật định kỳ
Google News RSS news.google.com/rss/search?q=UWB+OR+RTLS	Quét rộng theo từ khoá, miễn phí, dễ thêm từ khoá mới (ví dụ: tên đối thủ, tên ngành)

9. Hỗ trợ khách hàng: chatbot hỏi đáp trên tài liệu docs.leapslabs.com

Xây chatbot cho phép người dùng hỏi đáp trực tiếp, với toàn bộ kiến thức lấy từ docs.leapslabs.com. Chatbot hoạt động theo mô hình **RAG** (Retrieval-Augmented Generation): chỉ trả lời dựa trên nội dung tài liệu, kèm link trích dẫn tới trang docs liên quan; nếu không tìm thấy trong tài liệu thì trả lời 'không có trong tài liệu' thay vì bịa.

Cách làm (pipeline):

- **Bước 1 - Ingest tài liệu:** script tải toàn bộ trang docs.leapslabs.com (theo sitemap), chuyển sang markdown và chia nhỏ theo đoạn (chunking); chạy lại tự động hằng tuần bằng cron để cập nhật khi docs thay đổi.

- **Bước 2 - Đánh index:** tạo embedding cho từng đoạn và lưu vào vector database. Open WebUI có sẵn tính năng Knowledge (RAG built-in) nên không phải tự dựng.
- **Bước 3 - Hỏi đáp:** khi user đặt câu hỏi, hệ thống tìm các đoạn docs liên quan nhất, đưa vào context và model trả lời kèm link nguồn.
- **Bước 4 - Triển khai 2 giai đoạn:** (a) dùng nội bộ trước: team support dùng chatbot để soạn câu trả lời cho khách (người duyệt trước khi gửi); (b) khi chất lượng đã ổn định, nhúng widget chat công khai lên website/docs cho khách tự hỏi đáp, câu khó tự động chuyển sang người phụ trách.
- Log lại toàn bộ câu hỏi của khách: vừa đo chất lượng trả lời, vừa biết phần docs nào thiếu để bổ sung.
- Nội dung docs là công khai nên dùng model local (Qwen3 32B) hay API đều được; chạy local thì không tốn phí theo lượt hỏi.

Công cụ / framework dựng RAG chatbot:

- <https://docs.openwebui.com/>
- <https://docs.llamaindex.ai/>
- <https://python.langchain.com/docs/>

10. Rủi ro và biện pháp

Rủi ro	Biện pháp
Lộ dữ liệu nhạy cảm lên dịch vụ cloud	Quy định phân loại dữ liệu; dữ liệu mật chỉ dùng model local
AI trả lời sai (hallucination)	Người duyệt trước khi gửi khách hàng; yêu cầu AI trích nguồn
Chi phí vượt kiểm soát	Hạn mức theo người dùng; xem lại chi phí hằng tuần
Phản cứng lỗi/quá tải	UPS, backup cấu hình; theo dõi GPU; tạm chuyển sang cloud khi bảo trì
Ít người dùng sau đào tạo	Video demo để xem lại; đưa AI review vào quy trình merge request

Giá và thông số trong tài liệu tra cứu tháng 06/2026, có thể thay đổi; cần xác nhận lại khi mua sắm.